UTS Prediksi Modern & Machine Learning

Prediksi default pembayaran kartu kredit (Default of Credit Card Clients Dataset, 30.000 observasi)

Nama: Alverrell Gustivierda Zidna Fann

NIM: 2404220021

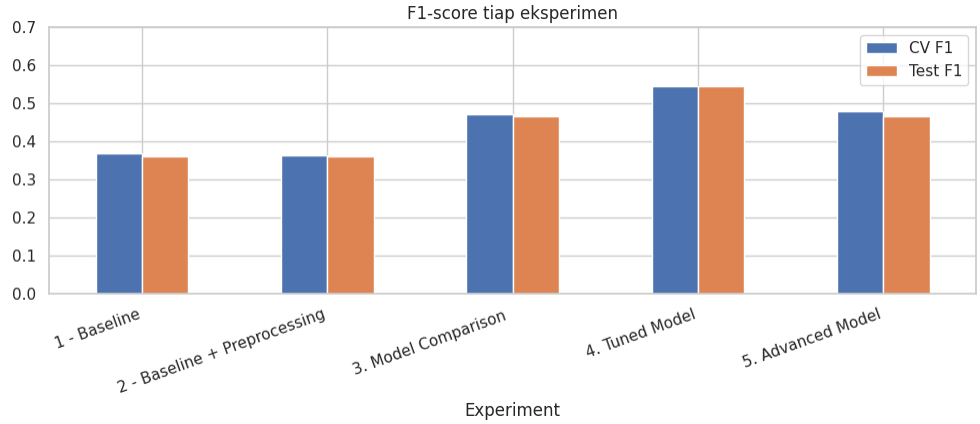
Data dibagi 80:20 secara stratified (24,000 data latih dan 6,000 data uji; proporsi default 22.1%) sebelum preprocessing apa pun. Semua evaluasi memakai 5-fold Stratified Cross Validation pada data latih. Metrik utama adalah F1-score (kelas default = 1); metrik pendukung adalah Accuracy, Precision, dan Recall. Model dipilih berdasarkan CV F1, bukan test set. Seluruh angka dalam dokumen ini diambil dari output notebook UTS_PMML_Credit.ipynb.

1. Summary of Experiment Results

Exp	Model	CV F1	Test Accuracy	Test Precision	Test Recall	Test F1
1	Baseline (Logistic Regression)	0.3692	0.8082	0.6841	0.2464	0.3623
2	Baseline + Preprocessing	0.3641	0.8088	0.6923	0.2442	0.3610
3	Model Comparison (Random Forest)	0.4704	0.8138	0.6371	0.3677	0.4663
4	Tuned Model (Random Forest, GridSearchCV)	0.5452	0.7927	0.5295	0.5607	0.5447
5	Advanced Model (XGBoost)	0.4783	0.8178	0.6630	0.3587	0.4655

Rincian model pada Experiment 3 dan Experiment 5:

Model	CV F1	Test Accuracy	Test Precision	Test Recall	Test F1
Logistic Regression (Exp 3)	0.3641	0.8088	0.6923	0.2442	0.3610
Decision Tree (Exp 3)	0.3957	0.7210	0.3749	0.3919	0.3832
Random Forest (Exp 3)	0.4704	0.8138	0.6371	0.3677	0.4663
Gradient Boosting (Exp 5)	0.4782	0.8190	0.6667	0.3632	0.4702
XGBoost (Exp 5)	0.4783	0.8178	0.6630	0.3587	0.4655



2. Experimental Analysis

Pertanyaan 1 - Apakah preprocessing pada Experiment 2 memberikan peningkatan performa dibandingkan baseline?

Tidak ada peningkatan yang berarti. Test F1 hanya berubah -0.0013 (dari 0.3623 menjadi 0.3610); accuracy 0.8082 menjadi 0.8088, precision 0.6841 menjadi 0.6923, recall 0.2464 menjadi 0.2442, sedangkan CV F1 justru turun -0.0051 (0.3692 menjadi 0.3641). Selisih sekecil itu berada jauh di dalam variasi antar-fold (simpangan baku CV F1 sekitar 0.013), sehingga preprocessing (pembersihan kategori, one-hot encoding, scaling) tidak memperbaiki Logistic Regression secara konsisten. Hal ini masuk akal: fitur penentu utama (PAY_x) sudah berbentuk ordinal numerik, dan masalah utama adalah recall rendah akibat ketidakseimbangan kelas yang tidak diselesaikan oleh scaling atau encoding. Preprocessing tetap dipertahankan karena membersihkan nilai kategori yang tidak terdokumentasi dan membuat prosedur lebih rapi, bukan karena menambah performa.

Pertanyaan 2 - Model apa yang memberikan performa terbaik pada Experiment 3 sebelum hyperparameter tuning?

Random Forest. Model ini memiliki CV F1 tertinggi (0.4704, dibanding Decision Tree 0.3957 dan Logistic Regression 0.3641) serta Test F1 tertinggi (0.4663, dibanding 0.3832 dan 0.3610). Urutannya konsisten antara CV dan test set. Logistic Regression unggul pada precision (0.6923) tetapi recall-nya sangat rendah (0.2442). Decision Tree tanpa pembatasan kedalaman cenderung overfit (accuracy hanya 0.7210). Random Forest memberi keseimbangan precision-recall terbaik, sehingga dipilih untuk tuning.

Pertanyaan 3 - Apakah hyperparameter tuning pada Experiment 4 meningkatkan performa model?

Ya. GridSearchCV (5-fold, scoring F1, 24 kombinasi) pada Random Forest menghasilkan kombinasi terbaik n_estimators=400, max_depth=12, min_samples_leaf=5, class_weight='balanced'. CV F1 naik dari 0.4704 menjadi 0.5452 (+0.0748) dan Test F1 naik dari 0.4663 menjadi 0.5447 (+0.0783). Kenaikan ini berasal dari recall (0.3677 menjadi 0.5607), dengan harga precision turun (0.6371 menjadi 0.5295) dan accuracy turun (0.8138 menjadi 0.7927). Penyebab utamanya adalah class_weight='balanced', yang membuat model lebih sering memprediksi default, ditambah pembatasan kedalaman dan min_samples_leaf yang mengurangi overfitting. Jadi F1 membaik karena trade-off precision-recall bergeser, bukan karena model lebih baik di semua metrik.

Pertanyaan 4 - Apakah model advanced pada Experiment 5 lebih baik daripada model terbaik dari eksperimen sebelumnya?

Tidak. Dua metode boosting yang diuji hampir setara (XGBoost CV F1 0.4783, Gradient Boosting 0.4782), dan XGBoost dipilih berdasarkan CV F1. Dibanding Random Forest hasil tuning, XGBoost lebih rendah: CV F1 0.4783 vs 0.5452 (-0.0669) dan Test F1 0.4655 vs 0.5447 (-0.0791). XGBoost unggul pada accuracy (0.8178) dan precision (0.6630), tetapi recall-nya hanya 0.3587. Catatan: boosting dijalankan dengan konfigurasi moderat tanpa tuning dan tanpa penanganan ketidakseimbangan kelas (misalnya scale_pos_weight), sedangkan Random Forest hasil tuning memakai class_weight. Hasil ini menunjukkan bahwa model yang lebih kompleks tidak otomatis lebih baik pada F1 di setting ini; belum tentu boosting kalah jika dituning setara.

Pertanyaan 5 - Berdasarkan seluruh eksperimen, model mana yang dipilih sebagai model final?

Model final adalah Random Forest hasil hyperparameter tuning (Experiment 4) dengan 400 pohon, max_depth=12, min_samples_leaf=5, dan class_weight='balanced'. Alasannya: (1) model ini memiliki CV F1 dan Test F1 tertinggi dari seluruh eksperimen (0.5452 dan 0.5447), dan urutannya konsisten di CV maupun test set; (2) recall-nya (0.5607) jauh lebih tinggi daripada baseline (0.2464) dan model lain, sehingga lebih banyak nasabah berisiko default yang tertangkap; (3) pemilihannya berdasarkan CV F1 pada data latih, bukan test set. Kelemahannya, precision turun menjadi 0.5295 dan accuracy menjadi 0.7927, artinya lebih banyak nasabah baik yang salah ditandai berisiko. Jika biaya salah menandai nasabah baik lebih besar daripada biaya melewatkan default, model dengan precision lebih tinggi (misalnya XGBoost) dapat dipertimbangkan.

3. Kesimpulan

Pada data yang tidak seimbang (sekitar 22% default), accuracy menyesatkan: baseline mencapai accuracy 0.8082 tetapi hanya menangkap 25% nasabah default (Test F1 0.3623). Preprocessing standar tidak mengubah hasil secara berarti; peningkatan terbesar datang dari pergantian model ke Random Forest dan dari hyperparameter tuning yang mencakup penanganan ketidakseimbangan kelas. Test F1 naik dari 0.3623 (baseline) menjadi 0.5447 (model final), sedangkan model boosting tanpa tuning (0.4655) tidak melampaui Random Forest hasil tuning. Seluruh eksperimen memakai random_state=42.